



Transfer Learning in Reinforcement Learning

ISIS4222 - Reinforcement Learning

Universidad de Los Andes - 2026-I

Elmar Santofimio Suarez | Harvy José Benitez Amaya
Diego Alberto Rodríguez Cruz

Agenda

01

Propósito e importancia

¿Por qué Transfer Learning en RL?

02

Fundamentos teóricos

Reward Shaping, LfD, Policy Transfer, Representaciones

03

Implementación y código

Notebooks ejecutables con DQN, Policy Distillation, TD3

04

Aplicaciones

Robótica, videojuegos, NLP, salud, sim-to-real

05

Perspectivas a futuro

Transferibilidad, interpretabilidad, framework-agnóstico

01

Propósito e Importancia

¿Por qué Transfer Learning es crucial en Reinforcement Learning?

¿Qué es Transfer Learning en RL?



Definición Formal


Dado un conjunto de dominios fuente M_s y un dominio objetivo M_t

TL busca aprender una política óptima π^* para el dominio objetivo, aprovechando información exterior D_s de los dominios fuente, además de la información interior D_t del dominio objetivo.

$$\pi^* = \operatorname{argmax} E[Q^{\pi}(s, a)]$$

donde $\pi = \phi(D_s, D_t) : S \rightarrow A$

Esquema Conceptual



Demostraciones

Políticas teacher

Funciones de valor

Reward shaping

Representaciones

¿Por qué RL normal no es suficiente?



Ineficiencia muestral

RL requiere **millones** de interacciones. En robótica o medicina, esto es prohibitivo por costos y seguridad.



Brecha sim-to-real

Políticas entrenadas en simulación fallan en el mundo real. TL facilita la adaptación entre dominios.



Exploración-Explotación

Sin conocimiento previo, el agente explora aleatoriamente. TL proporciona un punto de partida informado.



Sparse rewards


En tareas con recompensas escasas, el agente necesita guía externa (demostraciones, reward shaping).

02

Enfoques de Transfer Learning

Categorización por tipo de conocimiento transferido

Taxonomía de Enfoques TL en RL



Reward Shaping (RS)

Teoría

Idea central: Reconstruir la recompensa del dominio objetivo con conocimiento externo.

$$R' = R + F(s, a, s')$$

PBRs (Ng et al., 1999):

$$F(s, a, s') = \gamma\Phi(s') - \Phi(s)$$

Preserva la invarianza de política óptima:

$$Q^*_M(s, a) = Q^*_M(s, a) - \Phi(s)$$

Evolución: PBRs → PBA → DPB → DPBA

De potenciales estáticos a funciones dinámicas estado-acción.

Evolución de RS

PBRs

1999

$$F = \gamma\Phi(s') - \Phi(s)$$

PBA

2003

$$F = \gamma\Phi(s', a') - \Phi(s, a)$$

DPB

2012

$$F = \gamma\Phi(s', t') - \Phi(s, t)$$

DPBA

2015

Φ aprendido como Q extra

Learning from Demonstrations (LfD)

Concepto

$$DE = \{(s, a, s', r)\}$$

Las demostraciones guían al agente para explorar estados beneficiosos. Pueden ser:

Offline: Pre-entrenamiento de $V(s)$, π , o modelo de transición antes de RL.

Online: Demostraciones usadas directamente durante RL para exploración eficiente.

Reto principal: Demostraciones imperfectas o sub-óptimas.

Métodos Principales

Método	RL	Idea clave
DQfD	DQN	Buffer de replay priorizado
DDPGfD	DDPG	Prioridad + bias demostraciones
GAIL	TRPO	Adversarial distribution matching
POfD	PPO	RL obj + imitation matching
SAIL	DDPG	Auto-adaptativo, sub-óptimas

Policy Transfer: Distillation y Reuse

Policy Distillation

Teacher distillation: Expectativa sobre trayectorias del teacher.

$$\min_{\theta} E_{\tau \sim \pi_E} [\sum \nabla_{\theta} H \times (\pi_E | \pi_{\theta})]$$

Student distillation: Expectativa sobre trayectorias del student. Mejor exploración.

Ejemplos:

- Rusu et al. (2015): KL-Divergence multi-task
- Actor-Mimic: Cross-entropy teacher-student
- Distal: Política centroide + augmented rewards

Policy Reuse

Reúso directo de políticas fuente para construir la política objetivo.

Fernández & Veloso (2006): Selección probabilística de políticas basada en rendimiento esperado.

$$P(\pi_{Ei}) = \exp(tW_i) / \sum \exp(tW_j)$$

GPI (Barreto et al.): Extensión del teorema de mejora de política a múltiples políticas.

$$\pi(s) = \operatorname{argmax}_a \max_i Q^{\pi_i}(s, a)$$

Representation Transfer

Progressive Networks

Columnas por tarea, conexiones laterales transfieren representaciones. Pesos previos congelados.

$$h(k)_i = f(W(k)_i h(k)_{i-1} + \sum_j U(k:j)_i h(j)_{i-1})$$

Successor Features (SF)

Desacopla features de estado de la distribución de recompensas:

$$Q^{\pi}(s,a) = \psi^{\pi}(s,a)^T w$$

ψ : SR (reward-agnostic)
 w : reward mapper (task-specific)

UVFA

Aproximador universal: generaliza $V(s)$ para estados y goals ($G \subseteq S$).

$$V(s,g) = \phi(s)^T \psi(g)$$

Factorización matricial del espacio estado $\times$ goal.



Supuesto común

Existe un subespacio invariante a la tarea en S , A , o R , compartido entre dominios fuente y objetivo, sobre el cual se puede transferir conocimiento.

Métricas de Evaluación de TL



Abrev.	Métrica	Descripción	Evalúa
jp	Jumpstart Perf.	Rendimiento inicial del agente	Generaliz.
ap	Asymptotic Perf.	Rendimiento final del agente	Mastery
ar	Accumulated Rewards	Área bajo la curva de aprendizaje	Mastery
tr	Transfer Ratio	Ratio ap con TL / ap sin TL	Mastery
tt	Time to Threshold	Iteraciones para alcanzar umbral	Ambos
nka	Knowledge Amount	Cantidad mínima de conocimiento externo	Generaliz.
nkq	Knowledge Quality	¿Requiere oracle o tolera sub-óptimo?	Generaliz.

03

Implementación

Código ejecutable


Implementación: Notebooks Ejecutables



<https://github.com/diegoa-rodriquezc/UA-transfer-learning>

Resultados Experimentales CartPole

Transfer Learning en Deep RL: Comparación de Métodos



Métricas Clave

Jumpstart (jp)

60.0 Distill.

vs 18.8 baseline (+3.2x)

Asymptotic (ap)

140.4 PBRS

vs 122.8 baseline (+14%)

Accumulated (ar)

19,025 Distill.





vs 16,878 baseline (+12.7%)

Transfer Ratio (tr)

PBRS: 1.14 | Distill: 0.49

Resultados Experimentales HalfCheetah

Representation Transfer en Deep RL (TD3 - HalfCheetah)



Métricas Clave

Jumpstart (jp)

573.4 Fine-Tuning.

vs -394.2 baseline

Asymptotic (ap)

999.8 Fine-Tuning.

vs 590.1 baseline (+14%)

Accumulated (ar)

42,747 Fine-Tuning.

vs 9,026 baseline (+373%)

Transfer Ratio (tr)

Fine-Tuning:1.69 | Frozen:-0.34

04

Aplicaciones

Escenarios de aplicabilidad

Aplicaciones de TL en DRL



Robótica

Sim-to-real transfer, manipulación, locomoción. TRANSIC (2024), domain randomization. Agentes entrenados en simulación desplegados en robots reales.



NLP & Visión

Dialogue systems, VQA, Image Captioning. RS para sequence generation, policy distillation para grounded dialog.



Videojuegos

AlphaGo (LfD + MCTS), Dota2 (RS), Atari multi-task (policy distillation). Plataformas: Atari, StarCraft, MineCraft.



Salud & Energía

Tratamiento dinámico HIV (DQN + TL), drug delivery, control HVAC con sim-to-real TL (2024-2025).

¿Por qué no basta RL estándar?

Escenario	RL Estándar	Con Transfer Learning
Robótica real	Millones de pasos en hardware real → costoso, peligroso	Pre-entrenamiento en simulación, zero/few-shot transfer
Nuevo juego similar	Desde cero: ~10M frames	Policy distillation: ~2M frames (5x más rápido)
Sparse rewards	Exploración aleatoria, convergencia muy lenta	RS con $\Phi(s)$ o demostraciones guían exploración
Multitarea	Un agente por tarea	Representaciones compartidas (SF, UVFA)
Cambio de dominio	Reentrenar completamente	Inter-task mapping, domain randomization

05

Perspectivas a Futuro

¿Qué falta por hacer en Transfer Learning para RL?

Preguntas Abiertas y Futuro



Modelar Transferibilidad

¿Hasta qué punto el conocimiento de una tarea ayuda en otra? Selección automática de fuentes, evitar transferencia negativa. Mapeos gi: Si $\rightarrow$ ZS hacia un espacio latente consensual.



Interpretabilidad

Representaciones black-box dificultan depuración y confianza. TL interpretable: explicar qué conocimiento se transfiere y por qué. Crucial para salud y conducción autónoma.



Framework-Agnóstico

Mayoría de métodos TL son específicos a un framework RL (DQN, PPO, DDPG). Se necesitan enfoques unificados independientes del backbone RL.



Benchmarks Unificados

No existe un benchmark estándar para evaluar TL en RL. OpenAI Gym evalúa RL pero no TL. Se necesitan métricas y entornos estandarizados.

06

Conclusiones

Conclusiones generales

Conclusiones

El *Transfer Learning* permite reutilizar conocimiento previamente aprendido, reduciendo la necesidad de entrenar agentes desde cero y mejorando la eficiencia del aprendizaje.

Los resultados experimentales evidencian que la transferencia de conocimiento puede acelerar la convergencia, aumentar la estabilidad y mejorar el rendimiento final de los agentes.

La efectividad de las técnicas de transferencia depende directamente de la calidad y capacidad de adaptación del conocimiento transferido al nuevo entorno.

En el entorno *CartPole*, métodos como *Distillation* y *PBRs* mostraron ventajas complementarias según la métrica de evaluación utilizada.

En *HalfCheetah*, las representaciones transferidas demostraron ser útiles únicamente cuando el modelo pudo ajustarlas mediante procesos de *Fine-Tuning*.

Más que sustituir al *Reinforcement Learning* tradicional, el *Transfer Learning* se posiciona como una estrategia para hacerlo más eficiente, reutilizable y escalable frente a problemas complejos.

Referencias Clave

Zhu, Lin & Zhou (2021/2023). Transfer Learning in Deep Reinforcement Learning: A Survey. IEEE TPAMI.

Ng, Harada & Russell (1999). Policy invariance under reward transformations. ICML.

Ho & Ermon (2016). Generative Adversarial Imitation Learning. NeurIPS.

Rusu et al. (2015). Policy Distillation. arXiv.

Rusu et al. (2016). Progressive Neural Networks. arXiv.

Barreto et al. (2017). Successor Features for Transfer in RL. NeurIPS.

Schaul et al. (2015). Universal Value Function Approximators. ICML.

Hester et al. (2018). Deep Q-learning from Demonstrations. AAAI.

Parisotto et al. (2015). Actor-Mimic: Deep Multitask and Transfer RL. arXiv.

Jiang et al. (2024). TRANSIC: Sim-to-Real Policy Transfer. CoRL.

Coraci et al. (2025). Online TL for DRL controllers in buildings. Energy & Buildings.

Zhao, Queralta & Westerlund (2020). Sim-to-Real Transfer in DRL for Robotics: A Survey.



¡Gracias!

Transfer Learning in Reinforcement Learning

Universidad de los Andes